

Aire y Urgencias

Reconocimiento de fuentes: qué publica cada una, cómo se obtiene y qué condiciona el diseño

Este informe cierra la **etapa 1: reconocimiento de fuentes**. No contiene resultados del análisis de asociación — ese es el objeto de la etapa siguiente. Lo que documenta es qué entrega realmente cada fuente, cómo se accede a ella, qué se rompe al intentarlo y qué decisiones de diseño quedan abiertas.

Todas las cifras provienen de descargas y mediciones ejecutadas sobre los datos reales. Nada está estimado salvo donde se indica explícitamente.

Pregunta de investigación: cómo se asocia la variación de MP2.5 con la variación de consultas de urgencia por causa respiratoria en Santiago, Talcahuano y Coyhaique (2018-2024), controlando por temperatura, estacionalidad y período de pandemia.

Fecha: 6 de agosto de 2026

Fuentes reconocidas: OpenAQ (cerrada), DEIS/MINSAL (cerrada), SINCA/MMA (parcial)

Naturaleza del estudio: ecológico observacional. Se analiza *asociación*, nunca causalidad.

1. Resumen ejecutivo

Se reconocieron tres fuentes de datos. Las tres son accesibles desde la conexión del proyecto y ninguna quedó bloqueada. El período 2018-2024 está cubierto por completo en las tres. El proyecto es viable.

Los cinco hallazgos que cambian el diseño respecto de lo previsto son:

1. **El DEIS publica dato diario**, no semanal ni mensual, con los 365 días de cada año sin huecos. El alcance original suponía agregación semanal; ahora es una decisión y no una restricción.
2. **OpenAQ no replica el dato de SINCA: publica una transformación no declarada**. Lo que entrega para Chile es la media móvil de 24 horas del MP2.5 de SINCA, desplazada +10 µg/m³ y redondeada. Queda descartado como fuente de aire chileno, que era la sospecha inicial, pero por una razón más fuerte que la prevista.
3. **El esquema del DEIS cambia entre años**: formato de archivo, presencia de cabecera, formato de fecha, capitalización de nombres de columna y número de columnas. Un lector único falla.
4. **El archivo del DEIS mezcla totales agregados con detalle en la misma columna**, y una de las causas tiene un nombre que induce a error de dos órdenes de magnitud.
5. **Talcahuano dispone de una sola estación de MP2.5 con datos validados**, frente a doce en Santiago y dos en Coyhaique. Es el punto más frágil del diseño actual.

51,1 M

filas de urgencias del DEIS,
2018-2024

8,3 GB

DEIS descomprimido

9,8 GB

OpenAQ mundial comprimido

121

países en OpenAQ

19

estaciones SINCA de MP2.5 en las tres ciudades

2. Cómo se hizo

El reconocimiento siguió una regla: **ninguna afirmación sobre una fuente se acepta sin haberla comprobado contra el archivo real**. La documentación oficial se usó para orientar la búsqueda, nunca como evidencia.

2.1 Validación de cada descarga

El punto de partida fue que una respuesta HTTP 200 no significa que haya datos. Se comprobó en dos fuentes distintas:

- SINCA devuelve un **GIF vacío de 0 bytes con HTTP 200** cuando el parámetro de formato es incorrecto.
- El DEIS publica series cuyo recurso existe pero cuyo contenido viene sin filas.

Por eso toda descarga pasa por una cadena de comprobaciones antes de darse por buena:

- | | |
|--------------------|---|
| 1. código HTTP | 403 → sin permiso o bloqueo; 404 → no existe |
| 2. content-type | lo que el servidor declara |
| 3. números mágicos | lo que el cuerpo realmente es (PK\x03\x04 para ZIP) |
| 4. integridad | testzip() sobre el archivo completo |
| 5. contenido | que existan miembros y filas |

El control 3 es el que atrapa el caso peligroso: servidor que responde 200 con una página de error o una imagen. Nada se escribe en la zona cruda sin pasar los cinco.

2.2 Distinguir «bloqueado» de «inexistente»

La conexión del proyecto está detrás de CGNAT, lo que hace que un 403 sea ambiguo: puede ser la IP o puede ser que el recurso no exista. Confundirlos lleva a descartar datos que sí están. Se resolvió con contrastes dentro de la misma petición:

Observación	Interpretación	Cómo se determinó
openaq-fetches → 403 openaq-data-archive → 200	No es la IP: el bucket dejó de ser público	Misma IP y mismo cliente, dos resultados distintos
/DatosAbiertos/ → 403 /DatosAbiertos/AtencionesUrgencia/ → 404	No es la IP: el servidor IIS deshabilita el listado de directorios	El servidor devuelve códigos distintos según exista o no la ruta

2.3 No asumir esquema

Ninguna cabecera se dio por supuesta. Los lectores detectan codificación, separador y columnas, y registran qué variante encontraron. Esto no fue precaución teórica: los tres esquemas distintos de OpenAQ se descubrieron porque el propio muestreo falló con `KeyError: 'parameter'`, y la segunda partición del bucket apareció porque el conteo falló con `IndexError`. En ambos casos el fallo *era* el hallazgo.

2.4 Herramientas

Python 3.12 fijado con `uv`; pandas, pyarrow, statsmodels, boto3 (sin firmar, buckets públicos), requests y pyodbc. Antes de dar el entorno por bueno se ejecutó una prueba del pipeline completo en miniatura — CSV latin-1 con separador `;` y centinelas, agregación temporal, rezagos, modelo y escritura a Parquet — porque `uv` resolvió pandas 3.0, un salto mayor. La prueba pasó y no hizo falta fijar una versión anterior.

3. OpenAQ

Rol asignado: solo referencia internacional. Sirve para posicionar las tres ciudades frente al resto del mundo. No es fuente de datos chilenos.

3.1 Acceso

El bucket `s3://openaq-data-archive` responde sin credenciales (HTTP 200, firma `UNSIGNED`). La API, en cambio, está cerrada: `v3` devuelve `401` (exige clave) y `v2` devuelve `410 Gone`. Todo el catálogo hubo que derivarlo del propio bucket.

3.2 Estructura

El bucket tiene **dos árboles paralelos**, y esto no está documentado:

```
records/csv.gz/locationid=<id>/year=<yyyy>/month=<mm>/location-<id>-<yyyymmdd>.csv.gz
records/csv.gz/provider=<prov>/country=<iso2>/locationid=<id>/year=<yyyy>/month=<mm>/...
```

La vista plana por `locationid` no dice de qué país es cada estación. La vista por proveedor sí incluye `country=`, y es la única forma de contar países sin clave de API. Las dos vistas **no son equivalentes**: la de proveedor cubre 17.983 de 55.007 estaciones, es decir un tercio del archivo.

Formato: CSV comprimido con gzip, un archivo por estación-día, **codificación UTF-8** (verificado a nivel de bytes: `μ` llega como `\xc2\xb5`). Esto lo diferencia de las fuentes chilenas, que son latin-1.

El esquema no es uniforme

Estaciones	Columnas
195	<code>location_id</code> , <code>sensors_id</code> , <code>location</code> , <code>datetime</code> , <code>lat</code> , <code>lon</code> , <code>parameter</code> , <code>units</code> , <code>value</code>
10	igual, pero con <code>lat</code> y <code>lon</code> duplicadas
3	igual, pero con <code>measurand</code> en lugar de <code>parameter</code>

Sobre 208 estaciones muestreadas. Un lector que asuma la cabecera estándar falla en torno al 6 % de las estaciones. No hay columna de país, ni de ciudad, ni marca de validación.

3.3 Cobertura y volumen

Magnitud	Valor	Cómo se obtuvo
Estaciones (<code>locationid</code>)	55.007	conteo exhaustivo
Proveedores	49	conteo exhaustivo
Países	121	conteo exhaustivo vía proveedor
Estaciones chilenas	171	conteo exhaustivo (puesto 16 de 121)
Archivos 2018-2024	≈ 16,2 M	extrapolado de muestra de 250 estaciones
Disco comprimido	≈ 9,8 GB	extrapolado
Disco sin comprimir	≈ 243 GB	extrapolado (ratio medido: 24,8×)

Sobre el número de filas. La extrapolación da del orden de 74.000 millones, pero la media es de 4.570 filas por archivo mientras que la estación Parque O'Higgins tiene 20: la distribución está dominada por sensores de bajo costo que registran cada

minuto. Esa cifra debe tratarse como cota superior de orden de magnitud, no como conteo.

El volumen en bytes es manejable. Lo caro son los **16 millones de objetos pequeños**: el coste de listar y abrir domina sobre el de leer.

3.4 El hallazgo principal: OpenAQ publica una transformación

La sospecha inicial del proyecto era que OpenAQ duplicaba el dato de SINCA y que usarlo sería contar la misma medición dos veces. Se puso a prueba descargando el mismo mes y la misma estación de ambas fuentes y comparando hora a hora. **Se probaron desfases de -2 a +2 horas** para no confundir un desalineamiento temporal con una diferencia de valores.

Estación	Horas	Idénticas	Dif. media	Mejor desfase
Santiago / Parque O'Higgins	703	2,1 %	+10,5 µg/m ³	ninguno mejora
Temuco / Padre Las Casas II	674	0,7 %	+13,7 µg/m ³	ninguno mejora
Coyhaique II	676	0,7 %	+11,2 µg/m ³	ninguno mejora

Ningún desfase sube la coincidencia por encima del 2,4 %. No es un problema de alineación: son datos distintos. Los valores de OpenAQ resultaban además llamativamente suaves, lo que sugirió comparar contra medias móviles en vez de contra el dato horario.




Figura 1. La correlación con el dato horario es 0,596; con la media móvil de 24 horas, 0,9998.

RESULTADO

OpenAQ = redondeo(media_móvil_24h(SINCA validado) + 10)

La prueba decisiva no es la correlación sino la **desviación estándar del residuo: 0,2888**. El error de redondear a entero se distribuye uniforme en $[-0,5 ; 0,5]$, cuya desviación teórica es $1/\sqrt{12} = 0,28868$. La coincidencia a cuatro decimales significa que, una vez descontado el +10, *el único ruido que queda es el del redondeo*: la relación es determinista.

La fórmula reproduce el valor exacto en el 97,6 % de las horas en Parque O'Higgins y entre el 90 % y el 92 % en las demás. Se verificó en **cuatro estaciones de tres regiones**, con el mismo desplazamiento de +10 en todas, lo que indica un artefacto del procesamiento de OpenAQ y no una característica de las estaciones.

La hipótesis alternativa se probó y no se sostiene

Cabía pensar que la diferencia fuera preliminar contra validado. SINCA expone tres columnas excluyentes y en los períodos consultados la de preliminares está vacía:

Período (Parque O'Higgins)	Validados	Preliminares	No validados
junio 2024	714	0	0
junio 2025	719	0	0
junio 2026	718	0	0

Ni el mes más reciente disponible tiene preliminares pendientes. No hay diferencia de validación que explique la discrepancia.

Por qué exactamente +10 queda como pregunta abierta. El dato empírico es firme y suficiente para la decisión; el mecanismo que lo produce, no. No se investigó más porque no cambiaría la conclusión.

3.5 Consecuencias

- **OpenAQ queda solo como marco de referencia internacional.** No sirve como respaldo ni como fuente alternativa de MP2.5 chileno.
- **El percentil mundial de las tres ciudades debe calcularse con el dato de SINCA** insertado en la distribución de OpenAQ, nunca con el número que OpenAQ trae para Chile: sería comparar una media móvil desplazada contra los datos crudos del resto del mundo.
- **La idea de medir cuánto cambia un dato al validarse no es realizable** con estas dos fuentes. Lo observado no es validación, es transformación. Requeriría capturar el preliminar de SINCA en tiempo real y compararlo meses después: otro diseño.
- OpenAQ **no conserva marcas de validación** (no existe el campo) y **no trae meteorología** para las estaciones chilenas.

4. DEIS — Atenciones de Urgencia

4.1 Acceso

La ruta de descarga **no está enlazada desde ninguna página navegable**. La sección de datos abiertos de `deis.minsal.cl` se carga por JavaScript y no expone enlaces en el HTML; el registro del portal nacional de datos abiertos (creado en 2013 y nunca actualizado) apunta a `www.deis.cl`, dominio que **ya no resuelve en DNS**. La ruta se ubicó por búsqueda:

```
https://repositoriodeis.minsal.cl/SistemaAtencionesUrgencia/AtencionesUrgencia<AAAA>.zip
```

Años disponibles y verificados como ZIP íntegros: **2017 a 2026**. El período del estudio está cubierto por completo.

HALLAZGO DESTACADO

El DEIS publica dato diario, no semanal.

Cada año trae exactamente 365 días (366 en bisiestos), del 1 de enero al 31 de diciembre, sin huecos. El archivo incluye además una columna `semana` ya calculada. Como SINCA es horario, **ambos lados soportan resolución diaria**: la agregación semanal del alcance original deja de ser una restricción de los datos y pasa a ser una decisión de diseño.

4.2 El formato cambia entre años

Año	Contenido del ZIP	Formato
2018	<code>AtencionesUrgenciaLineal2018.mdb</code> + diccionario	Microsoft Access
2019	<code>AtencionesUrgencia2019.mdb</code> + diccionario	Microsoft Access
2020	<code>AtencionesUrgencia2020.csv</code> + diccionario	CSV
2021-2024	<code>AtencionesUrgencia<año>.csv</code>	CSV, sin diccionario

Los archivos Access pesan 1,10 y 1,11 GB descomprimidos. Se leen con el driver ODBC de Access de 64 bits, presente en el equipo, vía `pyodbc`. **Sin ese driver, 2018 y 2019 son ilegibles** y el período se reduciría a 2020-2024, que son justamente los años contaminados por la pandemia. El diccionario de datos oficial acompaña a los años 2018-2020 y deja de publicarse desde 2021.

4.3 El esquema no es estable

Año	Columnas	Cabecera	Campo de causa	Geografía
2018-2019	15	tabla Access	<code>Idcausa</code>	no
2020	15	no tiene	—	no
2021	15	sí	<code>IdCausa</code>	no
2022	15	sí	<code>Idcausa</code>	no
2023-2024	21	sí	<code>IdCausa</code>	sí

Cuatro rupturas concretas:

1. **2020 se publicó sin fila de cabecera.** La primera línea ya es un dato. Un lector con `header=0` perdería esa fila y usaría sus valores como nombres de columna.
2. **El formato de fecha cambia.** En 2020 las fechas son objetos `Date` de Java serializados (`Wed Sep 23 00:00:00 GMT-04:00 2020`); en 2018, 2019 y 2021-2024 son `dd/mm/aaaa`. Un único parser falla en uno de los dos grupos.
3. **IdCausa cambia de capitalización** solo en 2022.
4. **2023 añade seis columnas geográficas** (región, dependencia y comuna).

Codificación latin-1 y separador `;` en todos los años. Ningún año trae UTF-8.

Las columnas del Access no tienen nombre

En los archivos de 2018-2019 las seis columnas numéricas se llaman `Col01 ... Col06`, sin significado declarado, y sus tipos no siguen el orden esperado. **El mapeo no se asumió: se verificó** sobre las 4.488.935 filas de 2018:

```
Col01 = Col02 + Col03 + Col04 + Col05 + Col06 → 4.488.935 de 4.488.935 (100,00 %)
```

Queda establecido que el orden coincide con el del CSV: `Total, Menores_1, De_1_a_4, De_5_a_14, De_15_a_64, De_65_y_mas`.

4.4 Valores derivados y una trampa de nombre

El archivo **mezcla agregados con detalle en la misma columna**. Entre las 40 causas hay totales de sección que son suma de otras filas:

```
causas 3+4+5+6+10+11 (detalle respiratorio) = 4.939.422
causa 2 «TOTAL CAUSAS SISTEMA RESPIRATORIO» = 4.939.422 → idéntico
```

La coincidencia se repite en todos los años comprobados. Sumar todas las filas de causa cuenta cada atención al menos dos veces.

TRAMPA DE DOS ÓRDENES DE MAGNITUD

La causa **7 se llama CAUSAS SISTEMA RESPIRATORIO** y es fácil confundirla con las atenciones respiratorias. No lo es:

```
causas 7 + 8 + 22 + 23 = 548.790
causa 25 «SECCIÓN 2. TOTAL DE HOSPITALIZACIONES» = 548.790 → idéntico
```

La causa 7 pertenece a la Sección 2 del formulario: son **hospitalizaciones** por causa respiratoria, no atenciones de urgencia. Su magnitud (79.897 en 2018) es unas 60 veces menor que la causa 2. Usarla por su nombre subestimaría el indicador en dos órdenes de magnitud, sin error visible.

Filas que son agregados o encabezados de sección, no causas: `1, 2, 7, 8, 12, 18, 21, 22, 23, 25, 26, 34, 36, 42`.

No hay suavizado

A diferencia de OpenAQ, el DEIS publica **conteos brutos**. Los valores son enteros sin redondeo sospechoso y **la suma de los cinco grupos etarios iguala la columna Total en el 100 % de las filas**, en los cinco años CSV: cero discrepancias sobre unos 42 millones de filas. El único derivado son los totales por sección descritos arriba, que además están declarados en el diccionario.

4.5 Lo que el archivo permite

Causas respiratorias con CIE-10 explícito (esto es detalle, no agregado):

IdCausa	Glosa	CIE-10
3	Bronquitis / bronquiolitis aguda	J20-J21
4	Influenza	J09-J11
5	Neumonía	J12-J18
6	Otra causa respiratoria	J22, J30-J39, J47, J60-J98
10	IRA alta	J00-J06
11	Crisis obstructiva bronquial	J40-J46

Cinco grupos etarios en columnas separadas: menores de 1, 1 a 4, 5 a 14, 15 a 64 y 65 o más. Permite restringir a los grupos sensibles sin trabajo adicional. El total de causas distintas es 40 en todos los años: esto sí es estable.

4.6 Geografía: hay que cruzar con otra fuente

Lo que identifica al establecimiento es un código con formato **RR-NNN**. **Hasta 2022 el archivo no trae ningún campo geográfico**; región y comuna solo aparecen desde 2023. Para 2018-2022 la única vía de asignar una atención a una ciudad es cruzar con la *Base de Establecimientos* del año correspondiente, que aporta comuna, coordenadas y — hasta 2020 — fechas de vigencia.

Esa dimensión **también tiene esquema inestable**: pasa de 29 a 32 columnas, la clave cambia de nombre en 2020 (**Código Antiguo Establecimiento** → **Código Antiguo**), la cabecera está en la segunda fila y **las fechas de apertura y cierre desaparecen desde 2021**. El recambio de establecimientos, por tanto, no se puede leer de la dimensión: hay que inferirlo de la presencia o ausencia en cada base anual.

4.7 Volumen

Año	Filas	Formato	Descomprimido
2018	4.488.935	mdb	1,10 GB
2019	4.550.877	mdb	1,11 GB
2020	6.446.646	csv	1,02 GB
2021	8.816.240	csv	1,04 GB
2022	8.926.307	csv	1,06 GB
2023	8.899.080	csv	1,49 GB
2024	8.973.229	csv	1,50 GB
Total	51.101.314		≈ 8,3 GB

Comprimido en ZIP son 573 MB. La estructura es un producto cartesiano de establecimiento × causa × día, con los ceros explícitos: el archivo registra los días sin atenciones de una causa, lo cual es correcto — ausencia de fila no equivale a cero — pero infla el volumen unas 40 veces respecto del dato con contenido.

5. SINCA

Rol: única fuente de aire para Chile. El reconocimiento está parcialmente hecho; se completó lo necesario para el contraste con OpenAQ y para evaluar Talcahuano.

5.1 El patrón de descarga no está documentado

Se dedujo leyendo el JavaScript de la página de consulta:

```
https://sinca.mma.gob.cl/cgi-bin/APUB-MMA/apub.tsindico2.cgi
?outtype=xcl
&macro=.<REGIÓN>/<ESTACIÓN>/Ca/<PARÁM>//<PARÁM>.<resolución>.<agregación>.ic
&from=<AAMMDD>&to=<AAMMDD>
&path=/usr/airviro/data/CONAMA/&lang=esp&rsrc=&macropath=
```

Tres trampas, todas verificadas, y las tres hacen que un fallo parezca un éxito:

1. **outtype=xcl devuelve CSV**, pese al nombre. El valor **outtype=csv** devuelve un **GIF vacío de 0 bytes con HTTP 200**.
2. **Las barras del parámetro macro no deben codificarse**. Pasarlo por el mecanismo habitual de parámetros las convierte en **%2F** y el servidor responde el mismo GIF vacío.
3. Las fechas van en formato **AAMMDD**, de dos dígitos de año.

El servidor es Apache directo, sin CloudFront: el CGNAT no lo bloquea.

5.2 Las marcas de validación: el activo diferencial de SINCA

```
FECHA (YYMMDD);HORA (HHMM);Registros validados;Registros preliminares;Registros no validados;
230714;0100;50;;;
230714;0200;42;;;
```

Tres columnas excluyentes: un dato aparece en una sola. **Esta información no existe en ninguna otra fuente del proyecto** y resultó decisiva al evaluar Talcahuano.

5.3 Estaciones de MP2.5 en las tres ciudades

La web de SINCA declara la comuna de cada estación, de modo que la asignación no se infiere de coordenadas: se lee del catálogo oficial.

Ciudad	Región	Estaciones con MP2.5
Santiago	RM	D12 La Florida, D13 Las Condes, D14 Parque O'Higgins, D15 Pudahuel, D16 Cerrillos I, D17 El Bosque, D18 Cerro Navia, D27 Puente Alto, D28 Talagante, D29 Quilicura I, D30 Quilicura, D35 Cerrillos II (12)
Talcahuano	RVIII	802 Consultorio - San Vicente, 803 Libertad, 806 Inpesca, 807 Indura, 837 Nueva Libertad (5)
Coyhaique	RXI	B03 Coyhaique, B04 Coyhaique II (2)

Pendiente para completar el reconocimiento de SINCA: disponibilidad de temperatura y viento por estación, unidades, filas por estación-año y volumen nacional.

6. Cambio de ciudad: Temuco → Talcahuano

Talcahuano sustituyó a Temuco por ser una ciudad reconocida por su contaminación industrial. El cambio se recolectó por completo en las tres fuentes.

6.1 En SINCA: cinco estaciones, pero solo una utilizable

Se descargó la serie diaria completa 2018-2024 de las cinco estaciones y se miró en qué columna de validación cae el dato:




Figura 2. Solo **RVIII/802** publica datos validados. Las tres estaciones cuyo registro completo cae en «no validados» pertenecen a la red industrial; **RVIII/803** tiene macro publicado pero la serie viene vacía.

La estación utilizable cubre **2.427 de 2.556 días (95,0 %)**, repartidos de forma pareja entre 2018 y 2024. Es sólida, pero es una sola.

Se revisó el resto del Gran Concepción por si convenía ampliar el ámbito. Concepción, Chiguayante, Tomé, Coronel y Hualqui sí tienen estación validada. **Hualpén no:** sus tres estaciones son íntegramente no validadas, pese a compartir con Talcahuano la bahía de San Vicente y el cordón industrial.

6.2 En DEIS: Talcahuano es mejor que Temuco

	2018	2019	2020	2021	2022	2023	2024
Establecimientos	5	5	5	6	5	5	5
Urgencias respiratorias	75.568	70.439	13.992	13.671	54.804	59.084	52.853

Cobertura estable, sin el salto artificial de 5 a 11 establecimientos que tenía Temuco en 2020, y alrededor de un 40 % más de volumen en 2018-2019. Los cinco registran los 365 días del año casi sin excepción.

6.3 El identificador de establecimiento no es una clave estable

En Talcahuano tres códigos tienen presencia parcial y parecen tres establecimientos distintos: uno que cierra, otro que nace y muere, y un tercero que aparece al final. **Son dos, y uno cambia de identificador.** El cruce con la dimensión lo aclara:

base 2021:	antiguo=19-808	vigente=119808	SAPU Los Cerros	
base 2021:	antiguo=19-912	vigente=201018	SAR Los Cerros	
base 2024:	antiguo=201018	vigente=201018	SAR Los Cerros	← el código antiguo fue reemplazado

- 19-808 → 19-912 es una **conversión real**: SAPU Los Cerros se convierte en SAR Los Cerros. Se ve en el reparto de 2021 (117 días el SAPU, 306 el SAR).
- 19-912 → 201018 **no es un cambio de establecimiento**: es el mismo SAR Los Cerros, al que el DEIS empezó a identificar en 2024 con su código *vigente* en vez del *antiguo*.

La migración de codificación es progresiva y afecta a todo el país:

Año	Formato antiguo NN-NNN	Formato vigente NNNNNN
2022	622	16
2023	620	22
2024	609	31

Un análisis que trate el identificador como clave estable contará el mismo establecimiento dos veces y verá cierres y aperturas que no ocurrieron.

6.4 Balance del cambio

Aspecto	Temuco	Talcahuano
Estaciones SINCA con MP2.5 validado	3	1
Establecimientos DEIS	5 → 11 (salto)	5 (estable)
Urgencias respiratorias 2018-2019	≈ 52.000	≈ 73.000
Cobertura diaria DEIS	completa	completa

El cambio **mejora el lado salud y empeora el lado aire**. Talcahuano queda apoyado en una sola estación de MP2.5. Si esa estación tiene un vacío largo, la ciudad se queda sin exposición para ese período y no hay con qué rellenar dentro de la comuna.

7. El efecto de la pandemia

La pandemia hunde la consulta de urgencia en las tres ciudades (franja gris: 2020-2021)




Figura 3. Santiago cae al 25 % de su nivel de 2019 durante 2020-2021. El patrón se repite en las tres ciudades.

La caída es del orden del 75 % y afecta a las tres ciudades. No es una caída de la contaminación: es el efecto de la pandemia sobre la consulta de urgencia. **Controlar por período de pandemia no es opcional.**

Un matiz que conviene registrar: **Talcahuano no recupera su nivel previo.** Entre 2022 y 2024 se mueve en 53.000-59.000 frente a 70.000-76.000 en 2018-2019, alrededor de un 25 % por debajo, y con la misma cantidad de establecimientos registrando los 365 días. La caída no se explica por cobertura. Un control binario del tipo «2020-2021 sí, resto no» no captura esa diferencia de nivel.

8. Riesgos y decisiones que gatillan

Riesgo	Decisión que exige
El DEIS es diario y SINCA horario	Fijar la resolución del análisis. Bloquea el diseño de rezagos
Totales agregados mezclados con detalle	Filtrar siempre a <code>IdCausa ∈ {3,4,5,6,10,11}</code> . Nunca sumar todas las causas
La causa 7 parece respiratoria y es hospitalización	Excluirla explícitamente. Error silencioso de factor ≈ 60
2018-2019 en Access	Convertir a Parquet una sola vez. Sin el driver ODBC el período se reduce a los años de pandemia
2020 sin cabecera y con fecha en formato Java	Tratar 2020 como caso especial en el lector
Nombres de columna que cambian de capitalización	Normalizar al leer
Sin geografía hasta 2022	Cruzar con la Base de Establecimientos <i>de cada año</i> , no con una sola
El identificador de establecimiento cambia de formato	Normalizar códigos antiguo $\leftrightarrow$ vigente antes de construir series
Caída del 75 % en 2020-2021	Control de pandemia explícito, no un indicador binario de año
Talcahuano con una sola estación validada	Definir el ámbito espacial (ver §9)
Tres esquemas de CSV en OpenAQ	Normalizar cabeceras: <code>measurand</code> como alias de <code>parameter</code> , colapsar columnas duplicadas
16,2 millones de objetos pequeños en OpenAQ	Consolidar a Parquet particionado en la ingesta

9. Decisiones pendientes

9.1 ¿Resolución diaria o semanal? (bloquea el resto)

El dato diario permite ver la forma del rezago en vez de dos puntos, pero multiplica el volumen y exige tratar el efecto día de la semana, que en consulta de urgencia es fuerte. **Recomendación:** construir la tabla final diaria y agregar a semanal en el último paso, de modo que ambas opciones queden abiertas sin reprocesar.

9.2 ¿Cómo se define el ámbito espacial de Talcahuano?

Opción	Estaciones validadas	Valoración
Talcahuano estricto (comuna 8110)	1	Coherente con el alcance, pero frágil
Talcahuano + Hualpén	1	No se justifica: añade población sin añadir medición
Gran Concepción (8101-8112)	6	Análogo al Gran Santiago, pero diluye la señal industrial que motivó el cambio

Recomendación: la primera opción, con la tercera documentada como análisis de sensibilidad.

9.3 ¿Se pueden usar los datos no validados?

Las tres estaciones industriales de Talcahuano aportan unos 2.500 días cada una y cubrirían el período completo con tres puntos más de exposición. Pero mezclar validado con no validado exige una regla escrita, y conviene saber qué significa exactamente «no validado» en SINCA antes de usarlo. Entra en el reconocimiento pendiente de SINCA.

9.4 ¿Se empalma SAPU Los Cerros con SAR Los Cerros?

Es una conversión de servicio en el mismo lugar, no un cierre y una apertura. Empalmarlos da una serie continua para Talcahuano. **Recomendación:** empalmar y documentar la regla.

9.5 ¿Qué causas y qué grupos etarios entran?

Influenza e IRA alta pueden responder más a circulación viral que a contaminación — de ahí la utilidad de incorporar la vigilancia del ISP como control del confusor. Los menores de 5 y los mayores de 65 son los grupos sensibles, pero restringir a ellos reduce los conteos de Coyhaique, que ya son bajos.

10. Estado y qué sigue

Fuente	Estado	Qué falta
OpenAQ	Cerrada	—
DEIS (MINSAL)	Cerrada	—
SINCA (MMA)	Parcial	Meteorología por estación, unidades, volumen nacional, significado de «no validado»
ISP	No iniciada	Vigilancia de virus respiratorios, para el control del confusor
Reanálisis meteorológico	No iniciada	Temperatura donde SINCA no mide

Antes de pasar a la ingesta completa hay que **resolver la decisión 9.1**, porque condiciona el formato de todas las tablas intermedias, y **completar el reconocimiento de SINCA**, que es la única fuente de exposición del estudio.

Lo que queda en el repositorio

Ruta	Contenido
<code>docs/reconocimiento/hallazgos.md</code>	Documento completo con toda la evidencia y las tablas de riesgos
<code>src/ingesta/reconocer_openaq.py</code>	Acceso, partición, conteo, inventario, barrido y descarga
<code>src/ingesta/reconocer_deis.py</code>	Disponibilidad, descarga validada, comparación de esquemas, perfil y cobertura
<code>src/ingesta/sinca_cliente.py</code>	Cliente de descarga y catálogo de estaciones con su comuna
<code>src/ingesta/contrastar_openaq_sinca.py</code>	Contraste de validación entre fuentes
<code>docs/reconocimiento/_*.json</code>	Evidencia en crudo de cada medición citada en este informe

Los scripts son reejecutables y reproducen todas las cifras de este informe. Los datos descargados no se versionan: `data/` está excluido del repositorio, y la zona cruda es inmutable — todo reproceso parte de ella.